2026年4月9日

OshiruZine-AI

人工知能・機械学習・LLMを中心に、
技術トレンドから実用事例まで幅広く扱う技術系雑誌。

OshiruZine-AI

2026年4月9日 号

目次

1. Claude Code/Codexでのソフトウェア開発の最新ベストプラクティス　*スタンダード（約2000字）*
2. GPT-5・Gemini 2.5・Claude 4——2026年春のフロンティアモデル徹底比較　*特集（約4000字）*
3. EU AI Act 全面施行から半年——日本企業が今やるべきコンプライアンス対応　*スタンダード（約2000字）*
4. AIエージェント時代の『ツール呼び出し』設計パターン入門　*ショート（500〜1000字）*

Claude Code/Codexでのソフトウェア開発の最新ベストプラクティス

2026年に入り、AIコーディングアシスタントの勢力図は大きく塗り替わった。Anthropicの「Claude Code」とOpenAIの「Codex」——この二大ツールは、もはや"補助輪"ではなく"共同開発者"としてソフトウェア開発の現場に定着しつつある。しかし、ツールが高度化するほど「どう使いこなすか」の差が成果を大きく左右する。本コラムでは、2026年4月時点での最新動向を踏まえ、両ツールを用いた開発の実践的ベストプラクティスを整理する。

2026年春、両ツールの現在地

Claude Codeは2025年後半のメジャーアップデートでターミナルネイティブなエージェント機能を大幅に強化し、2026年2月のアップデートではマルチリポジトリ横断のコンテキスト理解が飛躍的に向上した。`CLAUDE.md`（プロジェクトルートに配置する指示ファイル）によるプロジェクト固有のルール定義が標準化され、チーム全体でAIの振る舞いを統一できるようになった点は特筆に値する。

一方のOpenAI Codex（旧Codex CLI）は、2026年1月にリリースされたCodex 2.0でサンドボックス実行環境が刷新され、コード生成→自動テスト→修正のループをエージェント内部で完結できるようになった。GPT-5ベースのコード理解力と、GitHub Copilotとのシームレスな連携が強みだ。

両者に共通するのは、「指示の質がアウトプットの質を決定する」という原則がますます鮮明になっている点である。

ベストプラクティス1：プロジェクトコンテキストの明示的な設計

最も効果が大きいのは、AIに渡すコンテキストを"設計"することだ。Claude Codeでは`CLAUDE.md`に、Codexではリポジトリ内の`.codex/instructions.md`に、以下を明記しておくことが推奨される。

- **アーキテクチャ方針**：モノレポ構成、レイヤー分離のルール、使用フレームワーク
- **コーディング規約**：命名規則、エラーハンドリングのパターン、禁止パターン
- **テスト戦略**：単体テストのカバレッジ基準、使用するテストフレームワーク
- **セキュリティ制約**：秘匿情報の扱い、外部API呼び出しのポリシー

2026年3月にAnthropic公式ブログで公開されたケーススタディでは、`CLAUDE.md`を適切に整備したチームがそうでないチームに比べ、生成コードの初回受け入れ率が約40%向上したと報告されている。"AIへの仕様書"をチームの成果物として管理する時代が来ている。

ベストプラクティス2：エージェントループの段階的委任

Claude CodeもCodexも、2026年現在では複数ステップのタスクを自律的に遂行する「エージェントモード」が実用レベルに達している。しかし、いきなり大きなタスクを丸投げするのは依然としてアンチパターンだ。

推奨されるアプローチは**段階的委任（Graduated Delegation）**である。

1. **スコープの小さいタスクから始める**：関数単位の実装、テストケースの追加、リファクタリングなど
2. **中間成果物をレビューしてから次へ進める**：差分の確認とテスト実行を人間がゲートとして挟む

3. **信頼度が上がったら範囲を拡大する**：機能単位、モジュール単位へとスコープを段階的に広げる

Claude Codeの`--auto-approve`フラグやCodexの`full-auto`モードは強力だが、本番コードに対しては慎重に使うべきだ。特にデータベースマイグレーションやインフラ変更を伴うタスクでは、必ず人間のレビューを介在させるガードレールを設けたい。

ベストプラクティス3：テスト駆動でAIを制御する

2026年の開発現場で最も効果が実証されているパターンが、**テストファースト×AI生成**のワークフローだ。人間がテストケースを先に書き、AIにそのテストをパスする実装を生成させる。こうすることで、AIの出力に対する客観的な合否基準が自動的に組み込まれる。

Claude Codeでは`/test`コマンドで既存テストスイートをエージェントに認識させた上で実装を指示でき、Codexではサンドボックス内でテスト実行結果をフィードバックループに組み込む機能が標準搭載されている。

このアプローチの副次的な効果として、テストカバレッジが自然と向上する点も見逃せない。AI活用をきっかけにテスト文化が根付いたというチームの報告が、国内外のテックブログで増えている。

ベストプラクティス4：セキュリティとコードレビューの再定義

AIが生成したコードに特有のセキュリティリスクは、2026年になっても完全には解消されていない。既知の脆弱性パターンの混入、ライセンス違反の可能性があるコード片の生成、ハルシネーションによる存在しないAPIの呼び出し——これらは依然として注意が必要だ。

対策として、CI/CDパイプラインに**AI生成コード専用の静的解析ステップ**を追加するチームが増えている。Semgrepの最新ルールセットにはAI生成コードに多い脆弱性パターンが含まれており、導入の敷居は低い。また、コードレビューに

おいても「このコードはAIが生成した」というメタ情報をコミットメッセージやPRテンプレートに含めることで、レビュアーの注意を適切に誘導する運用が定着しつつある。

両ツールの使い分けという現実解

現時点での実務的な使い分けとして、多くのチームが以下のような棲み分けに落ち着いている。Claude Codeは長い文脈の把握が必要なリファクタリングやアーキテクチャ分析に強く、Codexは既存のGitHub/VS Codeエコシステムとの統合やコード補完の即応性に優れる。両方を併用し、タスクの性質に応じて切り替えるハイブリッド運用がもっとも生産性が高いという報告が主流だ。

重要なのは、特定のツールに依存しすぎないことだ。プロジェクトコンテキストの設計、テスト駆動のワークフロー、セキュリティのガードレール——これらはツールに依存しない普遍的なプラクティスであり、次のツールが登場しても通用する資産となる。

AIコーディングアシスタントは、2026年の今もなお急速に進化し続けている。だからこそ、ツールの機能に振り回されるのではなく、「良いソフトウェアを作るための原則」をAI時代に再解釈し続ける姿勢が、エンジニアにとって最大のベストプラクティスなのだろう。

GPT-5・Gemini 2.5・Claude 4——2026年春のフロンティアモデル徹底比較

「もう、どれを選んでも同じでしょ？」——そんな声を現場で聞くことが増えた。たしかに2025年後半から2026年初頭にかけて、主要フロンティアモデルのベンチマークスコアは急速に収束しつつある。しかし、実際にプロダクションで数百万リクエストを捌いてみると、その"個性"は驚くほど鮮明だ。アーキテクチャ思想、料金設計、得意領域、そして何より「使い続けたときの手触り」が三者三様に異なる。

2026年4月現在、OpenAIの**GPT-5**（2025年末GA）、Google DeepMindの**Gemini 2.5 Pro/Ultra**（2026年2月GA）、Anthropicの**Claude 4**（2026年3月GA）が出揃い、まさにフロンティアモデル三国志の様相を呈している。本稿では、モデル選定に悩むエンジニア・研究者に向けて、公開情報と筆者チームの実測データを交えながら横断比較を行う。

アーキテクチャの変更点——何が変わったのか

GPT-5：Mixture-of-Experts の深化と "Adaptive Depth"

GPT-5で最も注目すべきアーキテクチャ変更は、OpenAIが「Adaptive Depth Routing」と呼ぶ推論時の動的レイヤースキップ機構だ。従来のMixture-of-Experts（MoE）がトークン単位でエキスパートを選択していたのに対し、GPT-5ではクエリの複雑度に応じてTransformerブロックそのものの通過数を変動させる。簡単な質問には浅い経路で即答し、複雑な推論には全レイヤーをフル活用する。これにより、公称パラメータ数は非公開ながら、推論コストの実効値を前世代比で約40%削減したとされる。

また、GPT-5はネイティブマルチモーダルを前提に設計されており、テキスト・画像・音声・動画の入力を統一エンコーダで処理する。特に動画理解能力は質的に飛躍しており、最大30分の動画からの構造的要約において、人間評価でGPT-4oを大きく上回る結果が報告されている。

Gemini 2.5：Long Context の限界突破と "Thinking" モードの統合

Gemini 2.5 Proは、先行して公開された実験版の反響を受けて正式リリースされた。最大コンテキスト長は**200万トークン**に到達し、実用上「本をまるごと1冊投げ込む」ワークフローが現実的になった。内部的にはRing Attentionの改良版と階層的キャッシュ機構を組み合わせ、長大なコンテキストでも注意の精度を維持する。

もう一つの大きな変化は、Gemini 2.5 Proの「Thinking」モード（旧Flash Thinking）が本体モデルに統合されたことだ。ユーザーが明示的にThinkingを有効化すると、Chain-of-Thought推論を内部で展開し、数学・コード生成・論理パズルでの正答率が飛躍的に向上する。Google DeepMindはこれを「System 2的推論のプロダクション統合」と位置づけており、APIパラメータ一つで切り替えられる手軽さが実運用で高く評価されている。

Gemini 2.5 Ultraはさらに上位のモデルで、科学論文の理解や高度な数学推論に特化したチューニングが施されている。ただし現時点ではAPI料金が高額であり、用途を絞った利用が推奨される。

Claude 4：Constitutional AI v3 と "Extended Thinking" の進化

AnthropicはClaude 4で、安全性フレームワークを「Constitutional AI v3」へアップグレードした。従来のRLHF＋憲法原則に加え、外部ツール呼び出し時の安全性制約を動的に評価する「Tool-Aware Safety Layer」を導入。エージェント的な利用が増える中で、ツール連鎖による意図しない副作用を抑制する仕組みだ。

アーキテクチャ面では、Claude 4はExtended Thinking（拡張思考）機能をさらに強化し、最大で内部思考トークンのバジェットを**128Kトークン**まで拡大可

能になった。これにより、複雑なコードベースの横断的分析や、大規模なリファクタリング計画の立案といったタスクで圧倒的な精度を見せる。また、コンテキストウィンドウも**100万トークン**に拡張され、Gemini 2.5には及ばないものの、多くの実用シナリオで十分なサイズだ。

ベンチマーク比較——数字が語る得意・不得意

以下は、2026年3月時点で公開されている主要ベンチマークの結果をまとめたものだ（各社公式発表および独立評価機関の数値を併記）。

ベンチマーク	GPT-5	Gemini 2.5 Ultra	Claude 4
MMLU-Pro (5-shot)	89.2%	90.1%	88.7%
GPQA Diamond	72.4%	74.8%	71.9%
HumanEval+ (コード)	93.1%	91.6%	94.3%
SWE-bench Verified	61.8%	58.3%	65.2%
MATH-500	96.1%	97.3%*	95.8%
Multilingual MMLU (日本語)	85.4%	83.7%	86.1%
RULER 128K (長文理解)	91.2%	95.8%	93.4%
Agentic Coding (SWE内部指標)	58.0%	54.2%	63.7%

*Gemini 2.5 UltraのMATH-500はThinkingモード有効時の数値。

いくつかの傾向が読み取れる。

コード生成・実務的ソフトウェアエンジニアリングではClaude 4が頭一つ抜けている。 SWE-bench VerifiedおよびAgentic Codingの両指標でトップであり、

大規模コードベースの文脈を保ったまま正確な修正を提案する能力は、筆者チームの体感とも一致する。

数学・科学推論ではGemini 2.5 Ultraが強い。 特にThinkingモードを有効にした場合のMATH-500は驚異的だ。ただし、Thinkingモード有効時はレイテンシが3〜5倍に増加する点は留意が必要。

汎用性とマルチモーダルのバランスではGPT-5がリード。 MMLU-Proこそ僅差だが、テキスト・画像・音声・動画を統合的に扱えるワークフローの完成度は現時点で最も高い。

日本語性能はClaude 4が意外に健闘。 Anthropicは日本市場への注力を明言しており、Claude 4の日本語チューニングは過去モデルから大きく改善されている。

料金体系——TCO（総所有コスト）で考える

2026年4月時点のAPI料金（1Mトークンあたり、USドル）を整理する。

モデル	入力	出力	備考
GPT-5	$8.00	$24.00	バッチAPIで50%割引あり
GPT-5 Mini	$1.50	$6.00	軽量タスク向け
Gemini 2.5 Pro	$3.50	$14.00	200Kトークン超は料金1.5倍
Gemini 2.5 Ultra	$10.00	$30.00	Thinkingトークンも課金対象
Claude 4	$6.00	$18.00	Extended Thinking分は別途課金
Claude 4 Sonnet	$2.00	$8.00	コスパ最強候補

単純なトークン単価だけ見るとGemini 2.5 Proが魅力的だが、Thinkingモードを多用すると内部思考トークンが加算されて実コストは倍増する。Claude 4もExtended Thinkingの利用状況次第でコストが大きく変動する。GPT-5はAdaptive Depthにより単純な問い合わせでは実質的に軽量モデル並みの速度・コストで応答するため、トラフィックの構成比によっては意外とコスト効率が良い。

筆者チームが社内チャットボット（1日あたり約50万リクエスト、平均入力500トークン・出力300トークン）で1週間の実コストを比較したところ、以下の結果になった。

- **GPT-5**：約$4,200/週（Adaptive Depthにより軽量ルーティングが多数を占めた）
- **Gemini 2.5 Pro**：約$2,800/週（Thinkingモード不使用時）
- **Claude 4 Sonnet**：約$2,100/週

ライトなタスクが多い場合はClaude 4 Sonnetのコスパが際立つ。一方、回答品質を最優先する場合はGPT-5やClaude 4フルモデルに軍配が上がるため、ルーティングレイヤーを設けて「簡単な質問はSonnet、複雑な質問はフルモデル」と振り分ける設計が2026年春のベストプラクティスになりつつある。

実運用での使い勝手——APIエコシステムと開発体験

レイテンシとスループット

Time to First Token（TTFT）の実測値（東京リージョン、2026年3月計測）は以下のとおり。

- **GPT-5**：約320ms（簡易クエリ時は約180ms）
- **Gemini 2.5 Pro**：約280ms

- **Claude 4**：約350ms（Extended Thinking無効時）

Gemini 2.5 ProはGoogle Cloudのインフラを活かしてTTFTが最も速い。GPT-5はAdaptive Depthの恩恵で軽量クエリ時のレスポンスが非常に速く、体感上のスナップ感が心地よい。Claude 4はやや遅めだが、ストリーミング出力の安定性は三者の中で最も高く、途切れや再接続の頻度が少ない印象だ。

ツール呼び出し（Function Calling）とエージェント性能

2026年のLLM活用における最大のトレンドは「エージェント」だ。ツール呼び出しの正確性・安定性はモデル選定の最重要ファクターになりつつある。

GPT-5はStructured Outputsの強化により、JSON Schemaに100%準拠した出力を保証する機能が安定している。複雑なネストを含むスキーマでもパース失敗がほぼゼロで、プロダクション環境での信頼性が高い。

Gemini 2.5 Proは、Google検索やGoogle Workspace連携などのネイティブツール群が充実しており、Googleエコシステム内でのエージェント構築では圧倒的に楽だ。ただし、カスタムFunction Callingにおいてはパラメータの型推論ミスが散見され、スキーマをより厳密に定義する必要がある。

Claude 4は、Anthropicが「Computer Use」として進めてきたGUI操作エージェント機能がさらに洗練された。また、MCP（Model Context Protocol）のエコシステムが急速に拡大しており、外部ツールとの統合における標準化で一歩先を行っている。コードベースの自律的修正タスクにおいては、三者の中で最も実用的なエージェント性能を示す。

安全性とガバナンス

エンタープライズ導入では安全性・コンプライアンスも重要な判断軸だ。Anthropicは前述のConstitutional AI v3で安全性のリーダーシップを維持している。OpenAIはGPT-5でInstruction Hierarchyを強化し、システムプロンプトの権限管理が細かく設定可能になった。Googleは「AI Safety by Design」フ

レームワークを全面適用し、EU AI Act対応を含むコンプライアンス機能をAPIレベルで提供している点が特徴的だ。

モデル選定の判断軸——結局どれを選ぶべきか

ここまでの比較を踏まえ、ユースケース別の推奨をまとめる。

コード生成・ソフトウェアエンジニアリング中心 → Claude 4を第一候補に。SWE-benchの実績に加え、MCPエコシステムによるツール連携の柔軟性が魅力。コスト意識が高いならClaude 4 Sonnetでも十分戦える。

数学・科学・リサーチ用途 → Gemini 2.5 Ultra（Thinkingモード）。コスト度外視で精度を求めるなら現時点で最高水準。論文のフルテキストを投入できる200万トークンのコンテキストも強力。

マルチモーダル（画像・音声・動画）を含む汎用アプリケーション → GPT-5。統合エンコーダによるシームレスなマルチモーダル処理は現時点で最も完成度が高い。Structured Outputsの信頼性もプロダクション向き。

コスト最適化が最優先 → Gemini 2.5 Pro（Thinkingモード不使用）または**Claude 4 Sonnet**。ルーティングレイヤーを組み合わせれば、品質を大きく犠牲にせずTCOを50%以上削減できる。

日本語中心のサービス → Claude 4または**GPT-5**。日本語ベンチマークでの差は僅少だが、Claude 4の日本語における自然さ・丁寧さは定性的に高い評価を得ている。

おわりに——"選ばない"という選択肢

最後に一つ、実務的なアドバイスを。2026年春の時点で最も賢いアーキテクチャは、**単一モデルに依存しないこと**だ。LLMゲートウェイ（LiteLLM、Portkey、OpenRouterなど）を介して複数モデルを抽象化し、タスク特性・コスト・レイテンシに応じて動的にルーティングする構成が急速に標準化している。

フロンティアモデルの競争は、2026年後半にも新たな局面を迎えるだろう。GPT-5のアップデート、Geminiの次世代版、Claude 4のマイナーリビジョン——いずれも予告されている。特定モデルに過度にカップリングした設計は、半年後に技術的負債になるリスクがある。

モデルは「道具」だ。道具箱の中身を常にアップデートしながら、最適な一本をそのつど選び取れる柔軟性こそが、2026年のAIエンジニアに求められるスキルセットではないだろうか。

EU AI Act 全面施行から半年——日本企業が今やるべきコンプライアンス対応

「うちはEU域内に拠点がないから関係ない」——もし今もそう考えているなら、かなり危険な状態だ。2025年8月に高リスクAI規制の本格適用が始まったEU AI Act（人工知能規則）は、施行から半年が経った今、域外適用の事例が次々と表面化している。2026年2月には、EU域内ユーザー向けにAI搭載製品を提供していた日本のSaaS企業が、欧州データ保護委員会（EDPB）との連携のもと、当局から初の是正勧告を受けたと報じられた。もはや「対岸の火事」ではない。本コラムでは、日本企業が"今すぐ"着手すべきコンプライアンス対応を、具体的なチェックリストと国内ガイドラインとの差分を交えて整理する。

EU AI Actの現在地——2026年春のアップデート

EU AI Actは段階的に施行されてきた。2025年2月に禁止AIプラクティス（ソーシャルスコアリング、リアルタイム遠隔生体認証の原則禁止など）の規定が先行適用され、同年8月には高リスクAIシステムに対する適合性評価・登録義務・品質管理体制の要件が全面適用に入った。そして2026年に入り、汎用目的AI（GPAI）モデルに対する透明性義務とシステミックリスク評価の運用が本格化している。

注目すべきは、欧州AI庁（AI Office）が2026年1月に公開した「高リスクAI適合性ガイダンス v1.2」だ。技術文書の具体的な記載項目やリスク管理システムの実装水準が初めて詳細に示され、「何をどこまでやればよいのか」が一段と明確になった。逆に言えば、"知らなかった"は通用しなくなったということでもある。

域外適用はどこまで及ぶのか

EU AI Act第2条は、EU域外に所在する事業者であっても、そのAIシステムの出力がEU域内で使用される場合には本規則が適用されると明記している。典型的に影響を受ける日本企業のパターンは以下の通りだ。

- **EU顧客向けにSaaS/APIを提供するAIベンダー**: チャットボット、需要予測、与信判定など
- **EU域内に子会社・販売代理店を持つ製造業**: AI搭載製品（自動検査装置、医療機器、車載AIなど）
- **GPAIモデルを組み込んだサービスのグローバル展開企業**: 基盤モデルの提供者として透明性義務を負う可能性

GDPRの経験を思い出してほしい。域外適用の規定は「まさか自社が」と思っている企業にこそ降りかかる。EU AI Actでは、域内に代理人（Authorised Representative）を設置する義務があり、未対応のままでは最大3,500万ユーロまたは全世界売上高の7%という制裁金リスクに直面する。

今すぐ使える対応チェックリスト

以下は、高リスクAIシステムを提供・運用する日本企業が優先的に取り組むべき項目を整理したものだ。

1. **リスク分類の棚卸し**: 自社が提供・利用するAIシステムをAnnex IIIの高リスクカテゴリ（雇用、教育、信用評価、法執行、重要インフラなど）に照らして分類する。
2. **適合性評価プロセスの構築**: 内部統制型（Module A）または第三者認証型の適合性評価手順を整備する。とくに生体認証関連は第三者認証が必須。
3. **技術文書の整備**: リスク管理手法、学習データのガバナンス（データ品質・バイアス分析）、性能指標、堅牢性テスト結果を文書化する。ガイダンス v1.2の記載項目を網羅しているか逐一確認すること。
4. **人間による監視（Human Oversight）の設計**: 自動意思決定プロセスに人間が介入・停止できるインターフェースとオペレーション手順を確立する。
5. **透明性・説明義務への対応**: 利用者へのAI使用の通知、システムの目的・限界の開示、意思決定ロジックの説明可能性を確保する。
6. **EU域内代理人の選任**: 物理的な拠点がない場合でも、域内代理人を正式に任命し、EUデータベース（高リスクAI登録簿）への登録を完了させる。
7. **インシデント報告体制の構築**: 重大インシデント発生時に市場監視当局へ報告する体制とタイムラインを社内で定義する。
8. **継続的モニタリングの実装**: 市場投入後のパフォーマンス監視、ドリフト検知、定期的な再評価の仕組みを技術・運用の両面で整備する。

国内ガイドラインとの差分を押さえる

日本では、総務省・経済産業省が策定した「AI事業者ガイドライン」（2024年4月公表、2025年改訂）がベースとなる。原則ベースで柔軟性が高い国内ガイドラインに対して、EU AI Actは法的拘束力を伴うルールベースの規制であり、両者のギャップを理解しておくことが必須だ。

観点	日本（AI事業者ガイドライン）	EU AI Act
法的性質	ソフトロー（自主的な遵守）	ハードロー（法的義務・罰則あり）
リスク分類	事業者の自主判断に委ねる	4段階のリスクレベルを法定義
適合性評価	求められていない	高リスクAIに義務化
技術文書	推奨レベル	法定の記載要件あり
登録義務	なし	EUデータベースへの登録が必須
制裁金	なし	最大3,500万EUR or 売上7%

特に注意したいのが、日本のガイドラインで「推奨」に留まっている技術文書の作成やバイアス評価が、EU AI Actでは法的義務になっている点だ。国内基準で「対応済み」と判断していても、EU基準では不十分となるケースは少なくない。

まず動くこと——半年後では遅い

2026年後半には、GPAIモデルの透明性義務に関する実施細則がさらに具体化される見通しだ。加えて、日本政府も2025年末の「AI制度研究会」論点整理を踏まえ、2026年度中の法制度化に向けた議論を加速させている。EUの規制対応で構築した体制は、近い将来の国内法制にもそのまま活かせる"先行投資"になる。

技術と規制は表裏一体だ。最先端のAIを開発・展開する力がある日本企業だからこそ、コンプライアンスを競争力の源泉に転換できる。チェックリストの最初の一項目でいい——今日から手を動かそう。

AIエージェント時代の『ツール呼び出し』設計パターン入門

2026年に入り、LLMが自らツールを選び、組み合わせ、タスクを完遂する「AIエージェント」は、もはやプロトタイプの域を超えた。OpenAIのGPT-5系列、GoogleのGemini 2、AnthropicのClaude 4がいずれもネイティブなツール呼び出し機能を強化し、さらにMCP（Model Context Protocol）の仕様v1.2が2026年3月に公開されたことで、エージェント構築の標準化は一気に加速している。本コラムでは、いま押さえるべき設計パターンと、見落としがちな落とし穴をコンパクトに整理する。

主要な設計パターン3選

1. シングルエージェント＋ツールリスト型 最もシンプルな構成。1つのLLMに利用可能なツール（API、DB検索、コード実行など）をリストとして渡し、Function CallingやMCPで逐次呼び出す。プロトタイピングに最適だが、ツール数が増えると選択精度が低下する点に注意が必要だ。

2. ルーター＋専門エージェント型（マルチエージェント） 入力を受け取る「ルーターエージェント」が意図を分類し、専門エージェントに委譲する。LangGraphやCrewAI、AutoGenなどのフレームワークが成熟し、2026年現在はこのパターンが本番環境で最も採用されている。MCPのセッション管理機能により、エージェント間のコンテキスト受け渡しも格段に楽になった。

3. プラン＆エクゼキュート型 まずLLMが実行計画（ステップ列）を生成し、それを別のループで逐次実行・検証する。複雑なワークフローの再現性と可観測性が高い反面、計画の修正コストが課題になる。OpenAIのTasksAPIやAnthropicのagent orchestration機能がこのパターンを直接サポートし始めている。

よくある落とし穴

- **ツール記述の曖昧さ**: ツールのdescriptionが不十分だと、LLMが誤ったツールを選択する。型情報・制約・ユースケース例まで含めた精密なスキーマ定義が精度を左右する。
- **無限ループとコスト爆発**: エージェントがツール呼び出しを繰り返し、トークンとAPI費用が急増するケースは依然として多い。最大ステップ数・タイムアウト・コスト上限のガードレールは必須だ。
- **権限管理の欠如**: MCPの普及でツール接続が容易になった分、エージェントが意図せず破壊的操作を実行するリスクも増している。最小権限の原則と、人間承認（Human-in-the-loop）ステップの組み込みを忘れてはならない。

まとめ

ツール呼び出しの設計パターンは「どこまでLLMに自律性を持たせるか」というトレードオフそのものだ。MCPとFunction Callingの標準化により接続のハードルは下がったが、信頼性・安全性・コスト制御の設計はエンジニアの腕にかかっている。まずはシンプルなパターンから始め、可観測性を確保しながら段階的に自律度を上げていく——それが2026年現在の現実的なベストプラクティスだ。