2026年4月27日

OshiruZine-AI

人工知能・機械学習・LLMを中心に、
技術トレンドから実用事例まで幅広く扱う技術系雑誌。

OshiruZine-AI

2026年4月27日 号

目次

1. Claude Code/Codexでのソフトウェア開発の最新ベストプラクティス　*スタンダード（約2000字）*
2. GPT-5・Gemini 2.5・Claude 4——2026年春のフロンティアモデル徹底比較と選定ガイド　*特集（約4000字）*
3. EU AI Act 全面施行から半年——日本企業が今すぐ対応すべきコンプライアンス実務　*スタンダード（約2000字）*
4. MCP（Model Context Protocol）が変えるAIエージェント連携の世界　*ショート（500〜1000字）*

Claude Code/Codexでのソフトウェア開発の最新ベストプラクティス

「AIにコードを書かせる」フェーズは、もう終わった。2026年春の現在、私たちは「AIと共にソフトウェアをアーキテクトする」時代に突入している。Anthropicの**Claude Code**とOpenAIの**Codex**は、単なるコード補完ツールから"自律的な開発エージェント"へと急速に進化した。ターミナル上でリポジトリ全体を理解し、テスト作成からリファクタリング、PRレビューまでをこなすこれらのツールを、現場のエンジニアはどう使いこなすべきか。最新の知見をもとに、実践的なベストプラクティスを整理したい。

エージェント型開発の現在地

2025年後半からの変化は劇的だった。Claude Codeは2025年5月のローンチ以降、数度のメジャーアップデートを経て、2026年初頭には**マルチファイル横断の自律タスク実行**と**長期メモリ（CLAUDE.md + プロジェクトコンテキスト永続化）**が安定稼働するようになった。一方のOpenAI Codex CLIもオープンソースとして公開され、GPT-4.1系モデルをバックエンドにサンドボックス内での自律コード生成・実行を実現している。

両ツールに共通するのは、「指示を出したら結果だけ受け取る」というブラックボックス運用ではなく、**人間が"設計意図"を明示的に伝え、AIがそれを忠実に実装する**という協調モデルが最も成果を出すという点だ。ここからは、その具体的な方法論に踏み込んでいく。

ベストプラクティス1：CLAUDE.mdとプロンプト規約の徹底設計

Claude Codeを導入したチームがまず取り組むべきは、リポジトリルートに配置する**CLAUDE.md**の整備だ。これはAIエージェントに対する"チーム開発規約書"として機能する。2026年現在のベストプラクティスでは、以下の要素を含めることが推奨されている。

- **アーキテクチャ概要**：ディレクトリ構成、主要モジュールの責務、依存関係の方針
- **コーディング規約**：命名規則、エラーハンドリングのパターン、禁止パターン（例：anyの使用禁止）
- **テスト戦略**：ユニットテストのカバレッジ基準、E2Eテストの実行方法
- **やってはいけないこと**：既存APIの破壊的変更、特定ライブラリの暗黙的導入など

Codex CLI側でも同等の仕組みとして`AGENTS.md`やシステムプロンプトのカスタマイズが用意されている。重要なのは、**曖昧さを排除し、AIが迷わない指示体系を構築する**ことだ。「良い感じに書いて」ではなく、「この関数はResult型でエラーを返し、例外はスローしない」と書く。人間同士のコードレビューで指摘する内容を、事前にドキュメント化しておくイメージが近い。

ベストプラクティス2：タスク分割と段階的実行

大規模な機能開発を一度のプロンプトで完了させようとするのは、2026年現在でもアンチパターンだ。コンテキストウィンドウが拡大しても（Claude 3.5 Opusは200Kトークン超を扱える）、**タスクの粒度を適切に分割し、段階的にレビューしながら進める**方が品質は圧倒的に高い。

実務で効果が確認されているワークフローは以下の通りだ。

1. **計画フェーズ**：実装方針をAIに提案させ、人間がレビュー・修正する

2. **実装フェーズ**：承認した方針に基づき、モジュール単位でコード生成
3. **検証フェーズ**：AIにテストを書かせ、実行結果を確認
4. **統合フェーズ**：既存コードベースとの整合性を人間が最終チェック

Claude Codeの `/compact` コマンドによるコンテキスト圧縮や、サブエージェントへのタスク委譲機能を活用すれば、このサイクルを効率的に回せる。

ベストプラクティス3：サンドボックスとセキュリティの確保

Codex CLIが採用しているネットワーク無効化サンドボックスは、セキュリティ面で優れた設計思想だ。AIが生成・実行するコードが外部に意図しない通信を行うリスクを構造的に排除できる。Claude Codeでも、権限管理の仕組みが強化され、ファイルシステムへのアクセス範囲やコマンド実行の許可リストを細かく制御できるようになった。

本番環境やCI/CDパイプラインにAIエージェントを組み込む場合は、**最小権限の原則**を厳格に適用すべきだ。具体的には、書き込み可能なディレクトリの制限、シークレット情報へのアクセス遮断、実行可能コマンドのホワイトリスト化が必須となる。

ベストプラクティス4：ヘッドレス運用とCI統合

2026年に入り急速に普及しているのが、**ヘッドレスモード（非対話型）でのCI/CD統合**だ。GitHub ActionsやGitLab CIのワークフロー内からClaude CodeやCodexを呼び出し、PRの自動レビュー、テスト不足箇所の自動補完、ドキュメント生成を行うパターンが定着しつつある。

この運用では、結果の**決定論性**が課題になる。同じプロンプトでも出力が変わり得るLLMの特性上、生成されたコードは必ず既存のテストスイートとlinterで検証し、パスしない場合は自動的にリトライまたは人間にエスカレーションするフローを組むことが推奨される。

両ツールの使い分けと展望

現時点での実用的な使い分けとしては、**複雑なリファクタリングやアーキテクチャ理解を伴うタスクにはClaude Code、明確に定義されたコード生成タスクやOSSプロジェクトでの軽量な自動化にはCodex CLI**という棲み分けが多く見られる。もちろん、チームの技術スタックやモデルの好みによる部分も大きい。

確実に言えるのは、これらのツールは「使うかどうか」ではなく「どう使いこなすか」の段階に入ったということだ。コードを書く能力そのものよりも、**AIへの指示設計力、アーキテクチャの言語化能力、そして生成結果を正しく評価する目**が、エンジニアの市場価値を左右する時代が来ている。道具は揃った。あとは、私たち自身のプラクティスをアップデートする番だ。

GPT-5・Gemini 2.5・Claude 4——2026年春のフロンティアモデル徹底比較と選定ガイド

「どのモデルを使えばいいのか分からない」——2026年春、この問いはかつてないほど切実になっている。OpenAIのGPT-5、GoogleのGemini 2.5 Pro/Ultra、そしてAnthropicのClaude 4。いずれも2025年後半から2026年前半にかけて相次いでリリース・メジャーアップデートされ、ベンチマークの数字だけを見れば三者とも「最強」を名乗れるスコアをたたき出している。しかし、実際のプロダクションワークロードにおいては、得意領域もコスト構造も運用上の"クセ"もまったく異なる。本稿では、2026年4月時点で入手可能な最新情報をもとに、3つのフロンティアモデルを多角的に比較し、エンジニアが自社のユースケースに最適な一手を選ぶための実践的な指針を提供する。

2026年春——フロンティアモデルの勢力図

まず現在の状況を整理しよう。

GPT-5は2025年後半に段階的なロールアウトが始まり、2026年初頭にAPI一般提供（GA）へと移行した。Mixture-of-Experts（MoE）アーキテクチャをさらに深化させ、ネイティブマルチモーダル入出力（テキスト・画像・音声・動画）に対応。最大コンテキスト長は標準で256kトークン、拡張モードで1Mトークンに達する。

Gemini 2.5 Pro/Ultraは2025年3月のPro版プレビュー公開を皮切りに、同年夏のUltra版リリース、そして2026年2月の「2.5.1」アップデートで推論性能を大幅に底上げした。Google独自のTPU v6e（Trillium）クラスタ上で訓練・推論を行い、最大コンテキスト長はUltraで2Mトークンという驚異的な長さを誇る。YouTube動画やGoogle検索との統合をネイティブに備える点も特徴だ。

Claude 4はAnthropicが2026年初頭に発表した最新世代で、Claude 3.5 Opusの後継として位置づけられる。Constitutional AI（CAI）v3を基盤とした安全性アーキテクチャを刷新し、「拡張思考（Extended Thinking）」機能の大幅強化によりステップバイステップ推論の品質が飛躍的に向上した。コンテキスト長は標準200kトークンだが、プロジェクト単位でのコンテキストキャッシュとの組み合わせにより、実質的に数百万トークン規模のナレッジを扱える設計になっている。

ベンチマーク比較——数字が語る得意・不得意

以下は、2026年4月時点で公開されている主要ベンチマークスコアの概要である（各社公式発表および第三者評価機関のレポートを統合）。なお、ベンチマークの数字は評価条件により変動するため、あくまで相対的な傾向として捉えてほしい。

ベンチマーク	GPT-5	Gemini 2.5 Ultra	Claude 4
MMLU-Pro（知識・推論）	93.2	92.8	91.5
GPQA Diamond（大学院レベル科学推論）	78.4	79.1	80.6
HumanEval+（コード生成）	94.1	91.7	95.3
SWE-bench Verified（実世界バグ修正）	62.8	58.3	67.1
MATH-500（数学推論）	98.2	97.8	97.5
MMLUマルチモーダル（画像+テキスト）	89.5	91.2	85.3
Needle-in-a-Haystack 1M（長文検索）	97.1	99.3	93.8*
多言語MGSM（多言語数学）	95.0	96.3	94.2

*Claude 4は200kコンテキスト内でのスコア。キャッシュ拡張時は別途評価が必要。

GPT-5は全領域でバランスよく高水準をマーク。特に数学推論とマルチモーダル理解のバランスが秀逸だ。**Gemini 2.5 Ultra**はマルチモーダル入力と超長文コンテキストで頭一つ抜けており、動画理解や多言語タスクでの安定性が際立つ。**Claude 4**はコード生成・実世界のソフトウェアエンジニアリングタスク、そして科学推論で最高スコアを記録しており、「深く考える」タスクへの適性が数字に表れている。

料金体系——TCO（総保有コスト）で考える

2026年4月時点のAPI公開価格を比較する（1Mトークンあたり、USD）。

モデル	入力単価	出力単価	キャッシュ入力	備考
GPT-5	$12.00	$40.00	$3.00	バッチAPIで50%割引あり
GPT-5 Mini	$1.50	$6.00	$0.375	軽量タスク向け蒸留モデル
Gemini 2.5 Ultra	$10.00	$30.00	$2.50	128k超は入力単価2倍
Gemini 2.5 Pro	$2.50	$10.00	$0.625	最もコスパが高い中間モデル
Claude 4 Opus	$15.00	$75.00	$3.75	Extended Thinking利用時は思考トークン分の出力課金あり
Claude 4 Sonnet	$3.00	$15.00	$0.75	実用面で最も選ばれている

一見するとGemini 2.5 Proのコストパフォーマンスが突出しているが、実際のTCOを計算するには以下の要素を考慮する必要がある。

- **トークン効率**: Claude 4はExtended Thinkingで内部思考トークンを大量に消費する。複雑な推論タスクでは出力トークンが想定の3〜5倍に膨れる場合があり、見かけの単価以上にコストがかさむ。
- **キャッシュ戦略**: 繰り返し同じコンテキストを送るRAG構成では、キャッシュヒット率がコストに直結する。3社ともプロンプトキャッシュを提供しているが、キャッシュの有効期限やスコープのポリシーが異なる。
- **レート制限とスループット**: GPT-5はTier 5以上の法人アカウントでTPM（Tokens Per Minute）が大幅に緩和される。Geminiは従量制ながらGoogle Cloud経由での専用スループット確保が可能。Claude 4はWorkbench経由のバッチ処理で実質スループットを上げられる。
- **無料枠・コミット割引**: Google CloudのVertex AI経由では長期コミット割引が適用されるケースがある。OpenAIもエンタープライズプランで年間契約割

引を提供中だ。

月間1000万トークン（入力7:出力3の比率）を処理する典型的なRAGワークロードで試算すると、**Gemini 2.5 Pro ≒ $55/月** < **Claude 4 Sonnet ≒ $75/月** < **GPT-5 Mini ≒ $88/月**となり、フルスペックモデルでは**Gemini 2.5 Ultra ≒ $160/月** < **GPT-5 ≒ $204/月** < **Claude 4 Opus ≒ $330/月**が目安だ（Extended Thinking非使用時）。

得意領域マッピング——ユースケース別ベストチョイス

ここからが本稿の核心だ。ベンチマークとコストを踏まえ、具体的なユースケースごとに「今選ぶならどれか」を整理する。

コード生成・ソフトウェアエンジニアリング

第一選択: Claude 4 Sonnet / Opus。SWE-benchでの突出したスコアが示す通り、既存コードベースの理解・修正・リファクタリングにおいてClaude 4は他モデルを一歩リードしている。特にAgentic Coding（AIエージェントによる自律的なコード変更）の文脈では、Claude 4のツール使用能力とステップバイステップ推論の正確性が強みになる。コスト重視ならSonnet、品質最優先ならOpusを選択。

次点: GPT-5。CopilotエコシステムやChatGPTのCanvas機能との統合を重視するなら有力。特にフロントエンド開発やプロトタイピングの速度ではGPT-5のマルチモーダル出力（コードと同時にUIプレビューを生成）が生産性を押し上げる。

大規模ドキュメント処理・長文分析

第一選択: Gemini 2.5 Ultra。2Mトークンのコンテキスト長とNeedle-in-a-Haystack 99.3%の検索精度は圧倒的だ。法務文書レビュー、特許分析、学術論文のサーベイなど、数百ページの文書を丸ごと投入して横断的に分析するワークロードには最適。Google Workspaceとのネイティブ統合により、Google

Drive上のドキュメントを直接コンテキストとして参照できる点も実務では大きい。

次点: GPT-5（拡張1Mモード）。Geminiには及ばないものの、1Mトークンでの安定性は十分実用的。Azure経由でのエンタープライズガバナンスが必要な場合はこちらが現実解になる。

科学研究・専門知識推論

第一選択: Claude 4 Opus（Extended Thinking有効）。GPQA Diamondでの最高スコアが物語るように、大学院レベルの物理学・化学・生物学の推論タスクにおいてClaude 4のExtended Thinkingは真価を発揮する。内部でChain-of-Thoughtを数千トークン規模で展開し、論理的な飛躍を最小化する設計思想が、科学的正確性を求める場面でフィットする。

次点: Gemini 2.5 Ultra。Google Scholarとの連携やグラウンディング機能を活用すれば、最新論文を参照しながらの推論が可能。ただし、ハルシネーション率はClaude 4のExtended Thinkingモードにやや劣る印象がある。

マルチモーダルアプリケーション（画像・動画・音声）

第一選択: Gemini 2.5 Ultra。ネイティブマルチモーダルの完成度が最も高い。特に動画理解においては、1時間超の動画を直接入力して内容をインデックス化・要約できる能力は他の追随を許さない。YouTube動画のURL指定だけでコンテキストに取り込める手軽さも実用上のアドバンテージだ。

次点: GPT-5。画像生成（DALL·E 4統合）と音声入出力のリアルタイム処理ではGPT-5がリード。対話型アプリケーションやカスタマーサポートなど、リアルタイムマルチモーダルインタラクションが必要な場面ではGPT-5が強い。

エージェントワークフロー・ツール使用

第一選択: GPT-5 + OpenAI Agents SDK。2025年にリリースされたAgents SDKの成熟度とエコシステムの広さは依然として業界随一。Function Calling、

Code Interpreter、ファイル検索といったビルトインツールの安定性が高く、マルチエージェント構成のオーケストレーションも最も枯れている。

僅差で: Claude 4 + MCP（Model Context Protocol）。Anthropicが推進するMCPのエコシステムは2026年に入って急速に拡大しており、GitHub、Slack、各種DB、CIツールとのMCPコネクタが続々と公開されている。特にdevopsやインフラ運用のエージェントではMCPの柔軟性が光る場面が増えてきた。

コスト最適化が最優先のバッチ処理

第一選択: Gemini 2.5 Pro。単純なテキスト分類、要約、データ抽出といったバッチ処理タスクでは、コストパフォーマンスでGemini 2.5 Proが頭ひとつ抜けている。Vertex AIのバッチ予測機能を利用すれば、さらに割安な料金が適用される場合もある。

次点: GPT-5 Mini（バッチAPI）。OpenAIのバッチAPIは50%割引が適用され、24時間以内の非同期処理でよければ実質$0.75/1M入力トークンまで下がる。

モデル選定フローチャート——迷ったらここから

最後に、意思決定を簡略化するためのフローを示す。

1. **コンテキスト長が500k超必要か？** → Yes → **Gemini 2.5 Ultra**
2. **主なタスクはコード生成・修正か？** → Yes → **Claude 4 Sonnet/Opus**
3. **リアルタイムマルチモーダル対話が必要か？** → Yes → **GPT-5**
4. **コスト最小化が最優先か？** → Yes → **Gemini 2.5 Pro** or **GPT-5 Mini バッチ**
5. **科学・学術的な高精度推論が求められるか？** → Yes → **Claude 4 Opus（Extended Thinking）**

6. **既存のクラウドインフラに合わせたい場合** → Azure → GPT-5 / GCP → Gemini / AWS → Claude 4

もちろん、実際のプロダクションではひとつのモデルに固定する必要はない。2026年の成熟したLLMOpsツールチェーン（LiteLLM、OpenRouter、各クラウドのモデルガーデン）を使えば、タスクの性質に応じて複数モデルをルーティングする**マルチモデルアーキテクチャ**が現実的な選択肢になっている。軽量な分類タスクはGemini 2.5 Proに、複雑な推論はClaude 4 Opusに、マルチモーダル入力はGPT-5に——こうした動的なルーティングが、品質とコストの両立を実現する最もスマートなアプローチだろう。

まとめ——「最強」は存在しない、「最適」を選べ

2026年春のフロンティアモデル三国志は、単純な優劣では語れない成熟フェーズに入った。GPT-5のバランスとエコシステム、Gemini 2.5のスケールとコスパ、Claude 4の推論深度とコード能力——それぞれが明確な強みを持ち、それぞれに弱点がある。重要なのは、自社のユースケース、既存インフラ、チームのスキルセット、そして予算制約を冷静に見極め、「最強のモデル」ではなく「最適なモデル」を選ぶことだ。

そして忘れてはならないのは、このフロンティアの地図は半年後にはまた書き換わるということだ。次の更新を見逃さないよう、アンテナを張り続けてほしい。

EU AI Act 全面施行から半年——日本企業が今す

ぐ対応すべきコンプライアンス実務

「うちはEU域内に拠点がないから関係ない」——もしまだそう考えているなら、その認識は今すぐアップデートすべきだ。2025年8月2日にEU AI Actの高リスクAIシステムに対する規制が本格適用されてから約8カ月。すでに欧州委員会のAIオフィスは複数の執行アクションを起こし、域外企業に対しても情報提供要請（Request for Information）を送付した事例が報じられている。GDPRがそうであったように、EU AI Actの域外適用はもはや「理論上の話」ではなくなった。本コラムでは、施行後半年で見えてきた執行の温度感と、日本の開発現場が具体的に何を準備すべきかを整理する。

施行後半年で何が起きたか——執行事例の速報

2026年初頭にかけて注目すべき動きがいくつかあった。まず、2025年末にEU AIオフィスが汎用目的AIモデル（GPAI）の提供者に対し、透明性義務の遵守状況について初の正式調査を開始したことだ。対象にはEU域外に本社を置く大手テック企業も含まれ、学習データの要約開示やコンテンツのAI生成表示といった義務への準拠が問われた。

さらに2026年2月～3月にかけ、フランスCNILとオランダ当局がそれぞれ、採用選考AIと信用スコアリングAIに対して高リスク分類の適合性に関する予備的調査を実施したことが公表されている。いずれもEU域内にサービスを提供する域外企業が調査対象に含まれた点が重要だ。GDPR施行初期と比べると、執行の立ち上がりは明らかに速い。各国当局がGDPRで培った域外企業への執行ノウハウを転用していることがその背景にある。

日本企業はなぜ「無関係」ではいられないのか

EU AI Actの適用範囲は「EU域内で上市（placing on the market）または供用（putting into service）されるAIシステム」に及ぶ。つまり、日本企業が開発したAIシステムであっても、そのアウトプットがEU域内のユーザーに対して利

用される場合は規制対象となり得る。SaaS型で提供されるAI機能、OEM供給されるAIモジュール、さらにはAPIとして組み込まれるモデルも例外ではない。

加えて、2026年3月に経済産業省と総務省が公表した「AI事業者ガイドライン」改訂案のパブリックコメント結果を見ると、国内ガイドラインもEU AI Actの高リスク分類やリスクマネジメントの枠組みを明示的に参照する方向で議論が進んでいる。つまりEU対応を先行して進めることは、来るべき国内規制への備えにもなるのだ。

開発現場で押さえるべき3つの実務ポイント

1. リスク分類の自己評価を行う

EU AI ActはAIシステムを「禁止」「高リスク」「限定リスク」「最小リスク」の4段階に分類する。開発現場がまず行うべきは、自社のAIプロダクトがどのカテゴリに該当するかの自己評価だ。特に注意すべきは、Annex IIIに列挙された高リスク領域——雇用・人事管理、信用評価、法執行、教育、重要インフラ管理など——にサービスが該当しないかの確認である。

実務上のアドバイスとしては、プロダクトごとに「AI Act リスク分類シート」を作成し、用途・対象ユーザー・影響を受ける基本的権利を一覧化することを推奨する。この評価は一度やれば終わりではなく、機能追加や用途拡大のたびに再評価が必要になる。CI/CDパイプラインのチェックリストに組み込むくらいの意識が望ましい。

2. 技術文書の「継続的」な整備

高リスクAIシステムには、設計仕様・学習データの記述・性能評価結果・リスクマネジメント措置などを含む技術文書（Technical Documentation）の作成と維持が義務づけられる。ここで日本企業がつまずきやすいのは「一度書いて終わり」にしてしまうケースだ。

EU AI Actが求めるのは、システムのライフサイクルを通じた文書の更新と、市場投入後のモニタリング（post-market monitoring）体制の構築である。モデルの再学習やファインチューニングを行うたびにドキュメントを更新するワークフローを設計しておく必要がある。MLOpsパイプラインにドキュメント生成の自動化ステップを組み込む企業も増えてきた。ツールとしてはモデルカードの自動生成やデータシートのテンプレート管理を行うオープンソースプロジェクトが実用段階にあるので、積極的に活用したい。

3. 監査対応と「説明可能性」の担保

高リスクAIには、適合性評価（Conformity Assessment）が求められる。一部の領域では第三者機関による外部監査が必要となるが、多くのケースでは自己適合宣言（Self-Assessment）が認められている。ただし、当局から調査を受けた際に「なぜこのシステムが適合していると判断したか」を合理的に説明できなければ、自己評価の信頼性自体が問われる。

説明可能性（Explainability）は技術的なXAI手法の話だけではない。意思決定プロセスの記録、バイアス評価の結果、人間による監視（Human Oversight）体制の設計根拠など、組織としてのガバナンスの説明が求められる。開発チームだけでなく、法務・品質管理部門を巻き込んだクロスファンクショナルな体制構築が不可欠だ。

今から始めるアクションプラン

施行後半年の現状を踏まえ、日本企業が今四半期中に着手すべきことを3点に絞る。第一に、自社AI製品・サービスのEU域内提供有無の棚卸しと、リスク分類の一次評価。第二に、技術文書テンプレートの策定とMLOpsへの組み込み。第三に、法務・開発・品質管理を横断するAIガバナンス会議体の設置だ。

EU AI Actの完全施行は2027年8月に予定されている次のフェーズ（汎用AIモデルへの全面的義務適用を含む）に向けてさらに加速する。国内のガイドライン改

訂も年内にとりまとめが見込まれる。「まだ早い」と思っている企業こそ、半年後に「もう遅い」と言わないために、今日から動き始めてほしい。

MCP（Model Context Protocol）が変えるAIエージェント連携の世界

2026年に入り、AIエージェント開発の現場で「MCP対応」という言葉を目にしない日はなくなった。Anthropicが2024年末にオープン仕様として提唱したMCP（Model Context Protocol）は、わずか1年余りでLLMと外部世界をつなぐデファクト標準へと駆け上がっている。OpenAI、Google DeepMind、Microsoftが相次いでサポートを表明し、2026年春時点ではMCPサーバーのエコシステムが数千規模に拡大した。なぜここまで急速に普及したのか——その背景とアーキテクチャ、そしてマルチエージェント構成での実践的なメリットを整理したい。

MCPの基本アーキテクチャ

MCPの設計思想はシンプルだ。LLM側を**MCPクライアント（Host）**、外部ツールやデータソース側を**MCPサーバー**と位置づけ、両者をJSON-RPCベースの標準プロトコルで接続する。サーバーは「Tools（関数呼び出し）」「Resources（データ参照）」「Prompts（テンプレート）」という3種類のプリミティブを公開し、クライアントは実行時にこれらを動的に発見・呼び出しできる。

従来はツールごとにアダプタを自前で書く必要があったが、MCPではサーバーさえ用意すればどのLLMクライアントからも統一的にアクセスできる。いわば**"AIエージェント版USB-C"**のような存在だ。

マルチエージェント構成で真価を発揮する理由

MCPの恩恵が最も大きいのは、複数のエージェントが協調するマルチエージェント構成だ。具体的には次の3点が挙げられる。

1. **ツール共有の標準化** — 各エージェントが同一のMCPサーバー群を参照できるため、エージェントごとにプラグインを再実装する必要がない。開発工数が大幅に削減される。
2. **権限とコンテキストの分離** — MCPのセッション管理により、エージェントごとに異なるスコープでツールを公開できる。OAuth 2.1ベースの認証・認可フローが2025年後半の仕様改訂で正式統合され、エンタープライズ要件にも対応しやすくなった。
3. **動的なケイパビリティ発見** — エージェントが実行時に利用可能なツールを問い合わせるため、構成変更時にハードコードを書き換える必要がない。エージェントの追加・削除が柔軟に行える。

今後の注目ポイント

2026年3月にリリースされた仕様ドラフトでは、**Streamable HTTP Transport**の安定化に加え、エージェント間通信を直接MCPレイヤーで扱う拡張提案が議論されている。これが実現すれば、オーケストレーションフレームワークへの依存をさらに減らせる可能性がある。

MCPは「LLMを賢くする技術」ではなく、「LLMを正しくつなぐ技術」だ。エージェント時代のインフラとして、今のうちにキャッチアップしておく価値は十分にあるだろう。